

Parte 1: Análise da Coleção — Discussão

Impactos da distribuição do vocabulário na engenharia de um motor de busca

Resumo dos Dados Obtidos

MÉTRICA	VALOR
Tamanho do vocabulário	1.462.694 palavras distintas
Total de palavras na coleção	429.496.756
Palavras que aparecem apenas 1 vez (<i>hapax legomena</i>)	694.778 47,5% do vocabulário
Stopwords NLTK (inglês) encontradas	153 de 198
Ocorrências de stopwords no corpus	207.945.437 48,4% do total

Discussão dos Impactos no Motor de Busca

A distribuição segue a Lei de Zipf. O gráfico rank × frequência (escala log-log) forma uma reta descendente ao longo da maior parte do vocabulário, confirmando que poucas palavras concentram a maioria das ocorrências, enquanto uma cauda longa de palavras raras representa quase metade do vocabulário, mas contribui muito pouco individualmente para o volume total de texto. Esse padrão orienta diretamente as decisões de engenharia do motor de busca:

1. Palavras frequentes (topo do ranking) têm baixo poder discriminativo

As 10 palavras mais frequentes (*"the", "of", "and", "to", "a", "in", "that", "was", "it", "is"*) são todas stopwords estruturais do inglês. Elas aparecem em praticamente todo documento da coleção, então indexá-las com o mesmo peso que termos raros não ajuda a diferenciar um documento relevante de um irrelevante — pelo contrário, infla o índice invertido com listas de postings gigantescas para ganho de recuperação quase nulo. Isso justifica dois pontos centrais do projeto: (a) a decisão de testar remoção de stopwords como uma das abordagens de pré-processamento na Parte 2, e (b) o motivo de funções de ranking como o BM25 (usado na Parte 3) penalizarem termos de alta frequência através do componente IDF — o próprio desenho do BM25 é uma resposta direta a esse comportamento Zipfiano.

2. Quase metade do corpus é estruturalmente "ruído" para recuperação

Stopwords somam 48,4% de todas as ocorrências de palavras na coleção. Isso significa que, sem qualquer filtro, quase metade do processamento de indexação e busca é gasto em termos que não ajudam a distinguir documentos. Remover essas palavras antes de indexar reduz substancialmente o tamanho do índice e o tempo de processamento (métricas a serem medidas na Parte 4), mas tem um custo: buscas por frases exatas que dependem de stopwords (ex. *"to be or not to be"*) ficam prejudicadas ou impossíveis. Esse trade-off motiva propor duas abordagens alternativas de pré-processamento na Parte 2, em vez de assumir uma única solução como "correta".

3. A cauda longa (hapax legomena) é cara para o índice, mas altamente informativa

47,5% do vocabulário aparece apenas uma vez em toda a coleção. Do ponto de vista de armazenamento, cada uma dessas palavras exige uma entrada própria no índice invertido, mesmo contribuindo para apenas um único documento — um custo desproporcional ao benefício médio. Por outro lado, justamente por serem raras, essas palavras costumam ser as mais discriminativas quando aparecem em uma consulta: um termo raro presente tanto na consulta quanto em um documento é um forte indício de relevância (o mesmo princípio por trás do IDF). Isso é particularmente relevante para esta coleção, cujo objetivo final é detecção de plágio — palavras raras e específicas de um documento-fonte são justamente as pistas mais fortes de que um trecho suspeito foi copiado dali.

4. A tokenização escolhida já demonstrou impacto mensurável

Um efeito colateral observado durante a análise: como o tokenizador usado (regex que mantém apenas letras) não preserva apóstrofos, contrações como *"don't"* e *"won't"* são quebradas em tokens separados (*"don"* + *"t"*), fazendo com que nenhuma contração da lista de stopwords do NLTK seja detectada corretamente (45 das 198 stopwords têm frequência zero na coleção, quase todas contrações). Isso evidencia como a etapa de pré-processamento — muitas vezes tratada como um detalhe trivial — pode silenciosamente alterar quais termos são reconhecidos como stopwords e, por consequência, todo o comportamento do motor de busca downstream. É um argumento adicional para tratar o pré-processamento como uma decisão de projeto a ser explicitamente comparada (Parte 2).

5. Natureza multilíngue da coleção infla o vocabulário

O tamanho do vocabulário (1.462.694 palavras distintas) é grande mesmo para um corpus de 429 milhões de palavras, o que se explica em parte pela composição da PAN-PC-2011: livros do Project Gutenberg em inglês, alemão e espanhol. Isso significa que o vocabulário observado mistura morfologia de três idiomas diferentes, além de nomes próprios e possíveis artefatos de formatação dos textos originais. Um motor de busca monolíngue (assumindo apenas inglês, como a lista de stopwords utilizada) terá parte do vocabulário — termos em alemão e espanhol — tratado como "ruído não filtrável", o que reforça a necessidade de considerar o idioma como parâmetro de configuração do pipeline de pré-processamento.