

Parte 2: Proposta de configuração de motores de busca

Abordagens propostas por etapa

ETAPA	ABORDAGEM A	ABORDAGEM B
Pré-processamento	Mínimo: tokenização + lowercase, mantém stopwords, sem stemming	Mantém stopwords, remove stopwords (NLTK) e aplica stemming (Porter)
Extração de subconsulta	Documento suspeito inteiro como uma única consulta	Janelas deslizantes de sentenças/parágrafos como subconsultas independentes
Expansão de subconsulta	Sem expansão (termos literais)	Expansão com sinônimos via WordNet (NLTK)

Discussão das 8 combinações

- 1. A + A + A (mínimo, documento inteiro, sem expansão)**

Baseline absoluta. Rápida de indexar e buscar, mas o sinal do trecho plagiado fica diluído dentro do documento suspeito inteiro, e stopwords (48,4% do corpus, medido na Parte 1) inflam a similaridade entre documentos que não têm relação real de plágio. Espera-se baixa precisão e recall.
- 2. A + A + B (mínimo, documento inteiro, com sinônimos)**

Tenta compensar a falta de normalização morfológica com sinônimos, mas o problema de diluição do sinal (documento inteiro como consulta) permanece. A expansão tende a piorar mais do que ajudar aqui, pois adiciona ainda mais termos genéricos a uma consulta já dominada por ruído estrutural (stopwords não removidas).
- 3. A + B + A (mínimo, janelas, sem expansão)**

Resolve o problema da diluição (janelas concentram o sinal na região correta do texto), mas ainda carrega o ruído de stopwords não filtradas em cada janela. Deve superar as combinações 1 e 2 em recall, por focar a busca na vizinhança correta do plágio.
- 4. A + B + B (mínimo, janelas, com sinônimos)**

Combina o foco por janela com expansão semântica, mas sem stemming, plágio obfuscado que alterou a forma da palavra (não só o sinônimo) continua sem solução. Pode ajudar em obfuscação lexical simples, mas não morfológica.
- 5. B + A + A (stopwords+stem, documento inteiro, sem expansão)**

Reduz ruído (stopwords) e normaliza variações morfológicas, mas herda o problema de diluição do documento inteiro como consulta. Melhor que a combinação 1, mas ainda limitada pela extração ingênua.

6. B + A + B (stopwords+stem, documento inteiro, com sinônimos)

Acumula duas camadas de normalização (morfológica + semântica) mas mantém o gargalo estrutural da extração por documento inteiro — o sinal do trecho plagiado continua concorrendo com todo o resto do texto não relacionado.

7. B + B + A (stopwords+stem, janelas, sem expansão)

Ataca os dois problemas mais custosos identificados na Parte 1 (stopwords com 48,4% de peso e vocabulário inflado por variação morfológica) e resolve a diluição via janelas. Espera-se bom desempenho em plágio literal ou com obfuscação leve (variação de forma da palavra, capturada pelo stemming). Fica sem cobertura apenas para obfuscação por sinônimo real (troca de palavra por outra de significado equivalente mas raiz diferente).

8. B + B + B (stopwords+stem, janelas, com sinônimos)

Combinação mais completa: ataca ruído estrutural, diluição de sinal e obfuscação lexical simultaneamente. Teoricamente a de maior recall entre as 8, especialmente para os casos de plágio simulado por reescrita humana (mencionados no `readme.txt` da coleção). O risco é queda de precisão: mais termos expandidos por janela aumenta a chance de recuperar documentos-fonte que compartilham apenas tema/vocabulário genérico, sem conter o trecho realmente copiado.

Combinações escolhidas para implementação

Escolhidas: Combinação 7 (B + B + A) e Combinação 8 (B + B + B)

Justificativa:

Pré-processamento B (remoção de stopwords + stemming) e extração B (janelas deslizantes) são, pelas razões discutidas acima, praticamente pré-requisitos para um resultado razoável nesta coleção — eles atacam diretamente os dois problemas mais custosos que a Parte 1 mediu empiricamente (peso de stopwords e diluição de sinal em documentos longos). Não faria sentido gastar o esforço de implementação em uma combinação que já sabemos, pelos dados da Parte 1, que provavelmente terá desempenho fraco (ex: qualquer combinação com extração A, documento inteiro).

Em vez de escolher duas combinações aleatórias entre as 8, optou-se por **fixar a configuração mais forte de pré-processamento e extração (B + B) e variar apenas a expansão de subconsulta (A vs. B)**. Isso isola exatamente a variável mais incerta teoricamente: sinônimos via WordNet ajudam a capturar plágio obfuscado por reescrita, mas também podem introduzir ruído e reduzir precisão. Comparar 7 e 8 responde diretamente a essa pergunta com uma comparação controlada (uma única variável muda entre as duas execuções), o que facilita atribuir qualquer diferença de $\text{precision}@k$ / $\text{recall}@k$ especificamente ao efeito da expansão — em vez de misturar esse efeito com mudanças simultâneas em pré-processamento ou extração.